

# 多分类器融合的情感分析方法研究

王超名

北京交通大学 软件学院

**摘要:** 近年来,随着 O2O 的迅速发展,外卖领域产生了大量的文本评论。在大数据时代,这些包含用户主观情感倾向的文本蕴含着大量有用的信息,人工分析文本的情感倾向效率极低,所以,利用计算机对文本进行情感分析具有巨大的应用价值。本文针对外卖领域文本评论,首先分析了基于情感词典的情感极性算法,构建了一个外卖领域的情感词典,增加一个新词典——短语词典,可以自动识别更多句式和短语。结果发现,和基于统计的情感分析方法相比,基于词典的情感分析代码量大,工作量大,并且实际效果还不如基于统计的方法。接着,本文分析了基于 k-近邻、朴素贝叶斯、最大熵模型、支持向量机的情感极性分析算法,发现基于最大熵模型的算法准确率最高。最后,本文提出采用多分类器并联 + 串联的混合融合的策略,使用置信平均,来决定句子的情感极性,准确率能提升 1 到 2 个百分点。另外,在爬虫的构建上,我们提出了 selenium + BeautifulSoup 的终极爬虫方案,可以直接打开浏览器与服务器交互,动态解析 JS 网页。

**关键词:** 多分类器融合; 情感分析; K-近邻; 贝叶斯; 最大熵; 支持向量机; 情感词典

## 0 引言

随着互联网的飞速发展,特别是微博、微信、论坛等的兴起,人们越来越多地通过网络发表自己的评论看法。在大数据时代,这些包含用户主观情感倾向的文本蕴含着大量有用的信息,人工分析文本的情感倾向效率极低,所以,利用计算机对文本进行情感分析具有巨大的应用价值。<sup>1</sup>

情感分析的研究已比较成熟,在粒度上,情感分析可以有三种划分:词语粒度、句子粒度和篇章粒度。<sup>2</sup>而每个粒度下,又有其相应的子任务。<sup>3</sup>

篇章粒度。篇章粒度上的情感分析主要考虑整个篇章的情感极性。Lee et al. 将传统机器学习方法应用于电影评论的情感分析,最后得到从篇章中提取出 unigrams 后 SVM 的分类效果最好。<sup>4</sup>这三种机器学习方法都是有监督的方法。而 Peter D. Turney 提出了一种无监督的方法进行篇章情感极性的自动分类。<sup>5</sup>篇章粒度有几个子任务,都有相应的研究尝试解决。比如,主客观分类<sup>6</sup>、review helpfulness<sup>7</sup>、垃圾观点检测<sup>8</sup>。

句子粒度。句子粒度的情感分析首先是判断句子是否主观或客观,然后将主观语句进行极性分类。Weibe et al. 提出主观性分析在句子中的有效性及其在自然语言处理的应用。<sup>9</sup>熊德兰等人提出了基于 HowNet 的语义距离和语法距离相结合的句子褒贬倾向性计算方法利用夹角余弦法对语义倾向进行了改进。<sup>10</sup>句子粒度的子任务有:观点检索<sup>11</sup>、观点问答<sup>12</sup>、观点摘要<sup>13</sup>。

词语粒度。词语粒度的情感分析主要是提取出评价对象,评价观点,实体,属性,特征及其情感倾向。<sup>141516</sup>

本文尝试对外卖领域的文本，进行句子粒度的情感分析。构建了适应外卖领域的情感词典，并提出 K-NN、Naïve Bayes、Maximum Entropy、SVM 的多分类器混合融合的情感分析方法。

# 1 预处理

## 1.1 构建爬虫

传统爬虫向服务器发送请求后，服务器返回相应的静态网页信息。而如今大多数网站，很多信息都利用 js 进行动态加载，传统爬虫根本无法获取到。所以，本文利用 Python 上 selenium 和 BeautifulSoup，构建了一个终极爬虫，能自动打开浏览器，模拟实际的网页点击事件和浏览事件，与 js 网页动态交互，能成功解析 js 动态网页，爬取外卖网站上的文本评论。

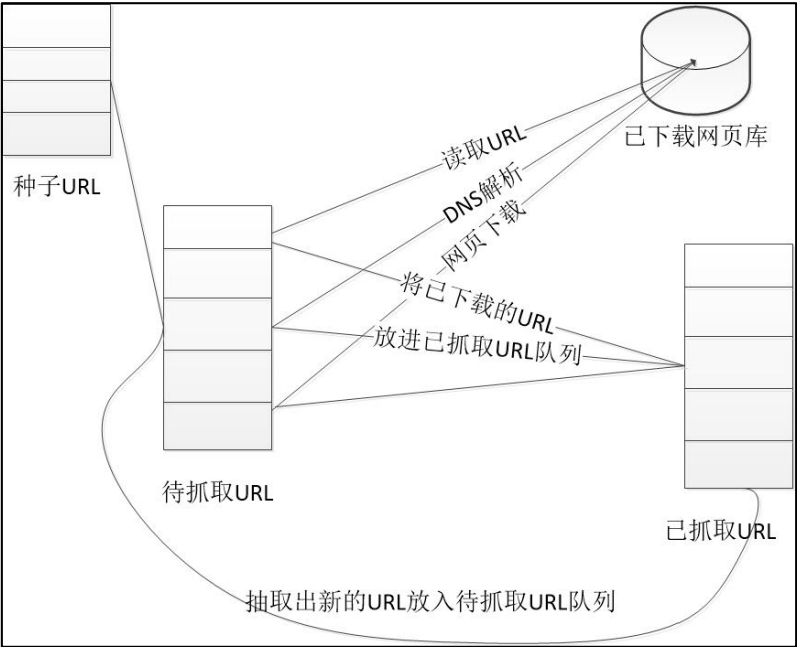


图 1：传统爬虫的工作原理。只能爬取静态加载的网页。

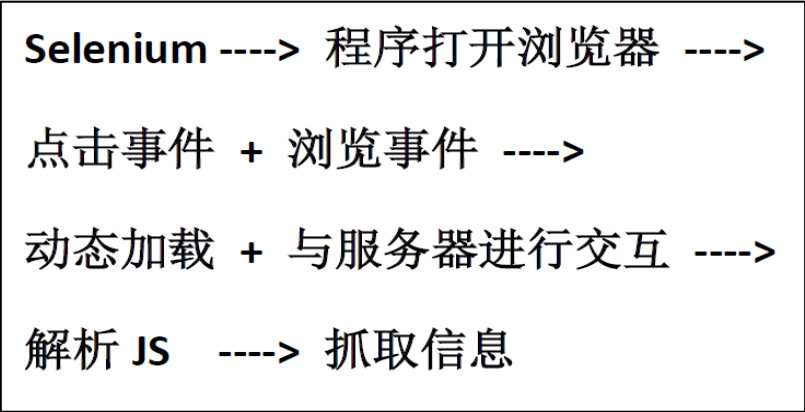


图 2：终极爬虫工作原理。能与服务器交互，动态加载网页。

## 1.2 特征选择

文本处理中，特征选择是一个非常重要的步骤，其目的在于从原始特征信息中，挑选出最具有代表性的、分类性能优异的特征进行分类，故合适的特征选择方法将很大程度上决定最终分类效果的好坏。通常情况下，文本分类领域都是选取词语作为特征，通过计算词语与类别之间的关系，度量各个词语对类别的贡献度大小，从而归属于某个类别。由于在文本数据处理中，往往词语的数量非常多，若把所有的词语都选为特征项，则特征空间的维度过大，不仅会增加运算量，还会影响分类的精度。因此须对文本内容作降维处理，合适的特征选择方法就尤为重要。情感分类中的特征选择，一方面需要去除与情感无关、类别关联度较小的特征，排除不必要干扰。另一方面，特征选择方法要能获取与情感分类有关联的特征信息，才能提高情感倾向性判别的准确性。<sup>17</sup>因此，必须针对外卖评论选择合适的特征抽取方法，才能提高情感识别的分类效果。本文采用 $X^2$ 统计方法：

$$X^2(t, C) = \frac{N(AD - BC)^2}{(A + C)(B + D)(A + B)(C + D)}$$

$X^2$ 统计方法度量特征词语  $t$  和句子类别  $c$  之间的相关程度，并假设  $t$  和  $c$  之间符合具有一阶自由度的 $X^2$ 分布。如果  $A$  表示包含词条  $t$  且属于类别  $c$  的句子频数， $B$  为包含  $t$  但是不属于类别  $c$  的句子频数， $C$  表示属于类别  $c$  但是不包含  $t$  的句子频数， $N$  表示语料中句子总数， $D$  表示既不属于  $c$  也不包含  $t$  的句子频数。<sup>18</sup>

实际上，如果类别是一个二分类别，则 $X^2(t, c1) = X^2(t, c2)$ 。

total_score	pos_score	neg_score	pos-num	neg-num	word
2616.32556	1308.16278	1308.16278	2762	240	不错
2139.55902	1069.77951	1069.77951	2853	397	很
1905.06747	952.53373	952.53373	2219	241	好
1744.33030	872.16515	872.16515	2450	367	好吃
1624.06672	812.03336	812.03336	1459	69	很好
1276.75156	638.37578	638.37578	1219	75	很快
1237.64500	618.82250	618.82250	1362	129	快
1183.08199	591.54099	591.54099	3234	3808	了
1130.73832	565.36916	565.36916	1186	99	非常
1081.58517	540.79258	540.79258	117	580	小时

图 3： $X^2$ 值前几名的词语。能看出这些词都是一些有效的情感词。“了”这样的词出现在其中，说明可以去除一些停用词，来进一步提高分类精度。

0.09101	0.04551	0.04551	10	6	肥肠
0.08866	0.04433	0.04433	24	15	软
0.08773	0.04386	0.04386	8	6	奶茶
0.08773	0.04386	0.04386	8	6	做生意
0.08773	0.04386	0.04386	8	6	食品
0.08773	0.04386	0.04386	8	6	素
0.08773	0.04386	0.04386	8	6	考虑

图 4： $X^2$ 值后几名的词语。能看出这些词的分类作用不是很大。

## 2 基于词典的情感分析

### 2.1 情感词典的构建

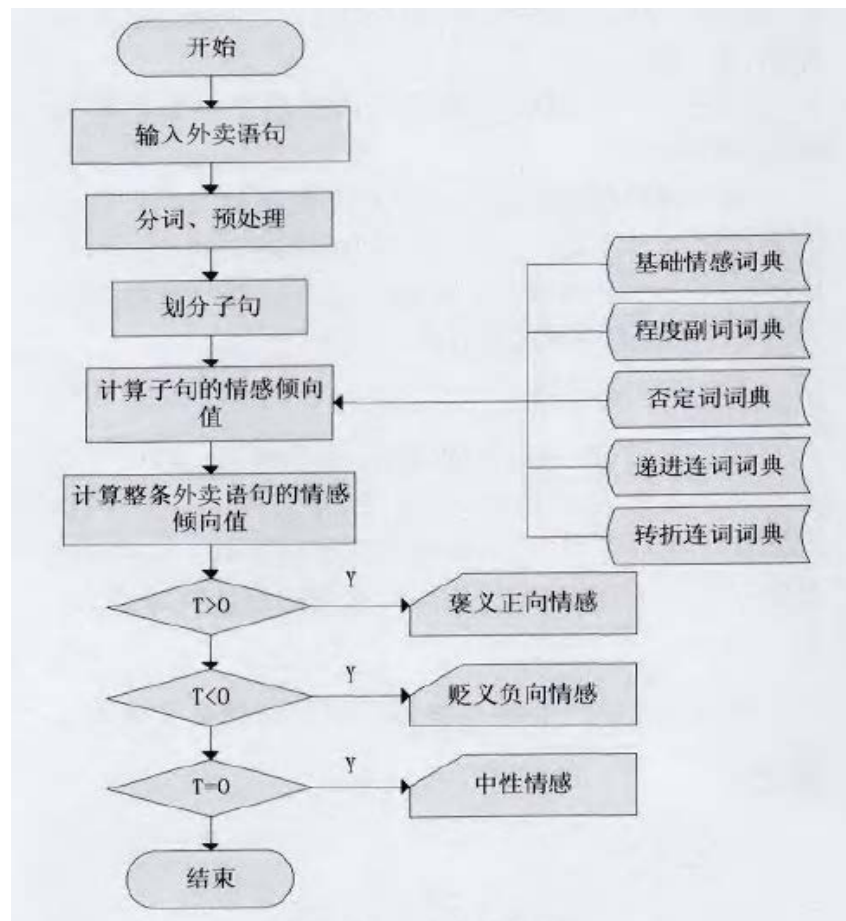


图 5：传统的基于情感词典的情感分析流程

文本的情感倾向大多通过情感词语来体现，情感词典能否覆盖全面在一定程度上影响着情感分类效果，故情感词典的构建是情感分类研究的基础。文本情感分析研究领域还没有一部完整且通用的情感词典。若构建一个面向外卖领域的情感词典，一方面须对当前的已有相关资源进行总结与整理，另一方面需要构建一个基于外卖的领域情感词典。本文选择中国科学院董振东教授构建的知网（HowNet）为基础情感词典，在此基础上，加上自己的副词词典、连词词典、否定词词典，完成情感词典的构建。另外，本文创造性地提出短语词典，自动识别更多句式和短语。



图 6：外卖领域情感词典的构成

文件(F) 编辑(E) 格式(O) 查看(V) 帮助(H)			
只送……菜	-1		
只有……菜	-1		
(把)?……撒……了	-2		
(把)?……洒……了	-2		
味……不对	-2		
没有……特点	-1		
看不见……肉	-1		
没……味道	-1	start:1 end:6	
没……味	-1	start:1 end:6	
没……肉……多	-1		
没……肉	-1	between_tag:m	
比……少	-1		
没……多	-1		
没……好吃	-1		
没……好	-1		
吃出……	-2	head:[^没]?	
扔了……	-1		
等……很久	-2		
(和 跟)……不(同 一样)	-1		

图 7：部分短语词典内容

## 2.2 情感分析算法

### 2.2.1 程序的调用层次

1. sentiment\_analysis\_from\_corpus\_file(path, encoding)
2. sentiment\_analyse\_a\_sentence(sentence, runout\_filepath=None)
3. divide\_sentence\_into\_clauses(the\_sentence)
4. sentiment\_analyse\_a\_clause(the\_clause, seg\_result=None)
5. clause\_is\_pattern\_2(the\_clause)
6. clause\_is\_pattern\_3(the\_clause, seg\_result)
7. emotional\_word\_analyse(core\_word, value, segments, index)
8. sentiment\_analyse\_a\_word(the\_word, seg\_result=None, index=-1)
9. word\_is\_conjunction(the\_word)
10. word\_is\_punctuation(the\_word)
11. word\_is\_positive(the\_word, seg\_result, index)
12. emotional\_word\_analyse(core\_word, value, segments, index)
13. word\_is\_negative(the\_word, seg\_result, index)
14. emotional-word\_analyse(core\_word, value, segments, index)
15. clause\_is\_pattern\_1(the\_clause)

### 2.2.2 程序的算法分析

- 1、首先将语句分成几个子句，分句为后续的情感分析做铺垫，若分句错误，后续的情感分

析将无从谈起。另外，分句要能识别出各种句式，诸如“如果……就……”。接下来对每一个分句进行分析，得到每个分句的情感分值，整句的情感分值为每个分句情感分值之和。

2、判断分句是否是句式二，即“如果……就”，“要是……就好了”。若是，则不管句式内有多少正向词语，直接判定为负向情感。比如，“要是肥牛再多点就好了”。

3、判断分句是否是句式三，句式三是各种短语，写进文件。每次读取文件，解析成正则表达式，进行匹配。比如，文件内为：“提高了……质量 2”会被解析成“提高了[\u4e00-\u9fa5]\*质量”，为正向短语，分值为 2；而“希望……提高……质量 -1”会被解析成“希望[\u4e00-\u9fa5]\*提高[\u4e00-\u9fa5]\*质量”，为负向短语，分值为-1。另外，还有一些特殊短语的解析，如：“没……味道 -1 start:1 end:6”会解析成“没[\u4e00-\u9fa5]{1, 6}味道”，而“没……肉 -1 between\_tag:m”会解析成“没[\u4e00-\u9fa5]\*肉”，并且中间必须有一个数词（词性 tag 为 m），匹配“没有几块肉”之类的句子。

4、将分句分词，分词利用 jieba 分词。然后逐个分析分词。首先判断是否是连词，是，则记录；判断是否是标点符号，是，则记录。判断是否是正向情感词，是则深度分析前三个视窗内的词。若有奇数个否定词，则正向情感分值变负；偶数个情感词，情感分值不变。若有副词，判断副词强度，“很”之类的词情感分值加倍，“不太”这类的副词，情感分值减半。

5、最后，加上之前记录的连词得倍数，标点符号的倍数，综合得到整个分句的情感分值。

2.3 实验结果

本文对正负各 1000 条外卖评论进行测试，实验结果如下：

pos-precision	pos-recall	pos-f1	neg-precision	neg-recall	neg-f1	total
79.82	80.7	80.26	80.49	79.6	80.04	80.15

可以发现，基于词典的情感分析方法，代码量大，人工构建量大，如果要构建一个高精度的基于情感词典的情感分析方法，人工工作量相当大。所以我们对基于机器学习的情感分析方法展开了研究。

3 基于 K-近邻的情感分析

3.1 k-近邻算法

k-近邻算法简单、直观。给定一个训练数据集，对新的输入实例，在训练数据集中找到与该实例最近邻的 k 个案例，这 k 个案例的多数属于某个类，就把该输入实例分为这个类。<sup>19</sup>

k 值的选择、距离的度量、分类决策规则是 k-近邻算法的三个基本要素。<sup>19</sup>

k 值的选择较小的优点是：“学习”的近似误差（approximation error）会减小，只有与输入

值较近的（相似的）训练实例才会对预测结果起作用。缺点是：“学习”的估计误差（**estimation error**）会增大，预测结果会对近邻的实例点非常敏感。如果邻近的实例点恰巧是噪声，预测会出错。

k 值的选择较大的优点：“学习”的估计误差（**estimation error**）会减小，“学习”的近似误差（**approximation error**）会增大。这时与输入实例较远的（不相似的）训练实例也会对预测起作用。使预测发生错误。

K-NN 算法的一般步骤：

- step1——初始化距离为最大值
- step2——计算未知样本和每个训练样本的距离 **dist**
- step3——得到目前 K 个最临近样本中的最大距离 **maxdist**
- step4——如果 **dist** 小于 **maxdist**，则将该训练样本作为 K-最近邻样本
- step5——重复步骤 2、3、4，直到未知样本和所有训练样本的距离都算完
- step6——统计 K-最近邻样本中每个类标号出现的次数
- step7——选择出现频率最大的类标号作为未知样本的类标号

### 3.2 实验结果

为了比较各分类器的精度比较，我们采用正负各 3500 条训练评论，正负各 1000 条作为测试数据，特征数为 4000。实验数据如下：

k	neg-right	neg-false	pos-right	pos-false	pos-precision	pos-recall
1	999	392	608	1	99.8358	60.8
3	956	414	586	44	93.02	58.6
k	pos-f1	neg-precision	neg-recall	neg-f1	total	
1	75.57	71.81884	99.9	83.56336	80.35	
3	71.9	69.78	95.6	80.68	77.1	

## 4 基于 Naïve Bayes 的情感分析

### 4.1 Naïve Bayes

假设句子 X 包含词汇  $(a_1, a_2, \dots, a_m)$ 。Y 为两类情感极性的集合  $(y_1, y_2)$ 。则 X 的情感极性为  $\text{argmax}(P(y_i|X)) = \text{argmax}(P(y_i|x_1, x_2, \dots, x_m))$ 。

由贝叶斯公式

$$P(y_i|x) = \frac{P(x|y_i)P(y_i)}{P(x)}$$

$P(x)$ 是相同的，可直接忽略。

Naïve Bayes 被称为 naïve 是因为假设各个词之间是相互独立的，所以我们可以得到：

$$P(x|y_i)P(y_i) = P(a_1|y_i)P(a_2|y_i)\dots P(a_m|y_i)P(y_i) = P(y_i) \prod_{j=1}^m P(a_j|y_i)$$

Naïve Bayes 的条件独立假设看上去很傻很天真，但结果去很强大。因为有些独立假设在各个分类之间的分布都是均匀的所以对于似然的相对大小不产生影响；即便不是如此，也有很大的可能性各个独立假设所产生的消极影响或积极影响互相抵消，最终导致结果受到的影响不大。<sup>20</sup>

## 4.2 实验结果

我们使用正负 3500 条训练评论，正负 1000 条作为测试数据。实验结果如下：

feature	pos-precision	pos-recall	pos-f1	neg-precision	neg-recall	neg-f1	total
all	86.77	66.18	75.09	72.67	89.91	80.37	78.05
4000	91.10	69.6	78.91	75.40	93.2	83.36	81.4

## 5 基于最大熵的情感分析

### 5.1 最大熵

1957 年 Jaynest<sup>21</sup>基于信息熵理论建立了最大熵模型。最大熵模型是根据样本信息对某个未知分布做出推断的一种方法。最大熵在自然语言处理等各领域应用非常广泛。<sup>22</sup>最大熵原理指出，当我们需要对一个随机事件的概率分布进行预测时，我们的预测应当满足全部已知的条件，而对未知的情况不要做任何主观假设。在这种情况下，概率分布最均匀，预测的风险最小。因为这时概率分布的信息熵最大，所以人们称这种模型叫"最大熵模型"。

#### 5.1.1 定义

我们假设  $\mathcal{P}$  为最大熵模型的学习后的所有条件概率， $p(y|x)$  为  $\mathcal{P}$  中的一个元素。训练集内包含大量的样本， $(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)$ 。我们定义  $\tilde{p}(x, y)$  为样本  $(x, y)$  出现的概率。从训练集中我们可以得到很多有用的特征，我们定义一个特征函数：

$$f(x, y) = \begin{cases} 1 & \text{满足特征条件} \\ 0 & \text{不满足特征条件} \end{cases}$$



特征函数在满足成为一个特征时取值 1，否则取值 0。则特征函数的经验概率为：

$$\tilde{p}(f) \equiv \sum_{x,y} \tilde{p}(x,y) f(x,y)$$

### 5.1.2 满足所有已知条件

而在最大熵模型中，特征函数的期望概率为：

$$p(f) \equiv \sum_{x,y} \tilde{p}(x)p(y|x) f(x,y)$$

最大熵模型的训练，就是满足这样一个约束条件——模型的期望概率与训练集中得到的经验概率相等：

$$p(f) = \tilde{p}(f)$$

即，

$$\sum_{x,y} \tilde{p}(x)p(y|x) f(x,y) = \sum_{x,y} \tilde{p}(x,y) f(x,y)$$

所有这样的约束组成一个集合  $\mathcal{C}$ 。

### 5.1.3 对未知条件尽可能均匀

现在，最大熵模型已经满足了所有约束条件了。那对于未知条件，我们要尽可能均匀（uniform）。那怎样才能达到“尽可能均匀”呢？一个衡量均匀分布的数学度量为熵：

$$H(p) \equiv - \sum_{x,y} \tilde{p}(x)p(y|x) \log p(y|x)$$

当所有情况概率都相等时，熵最大。

### 5.1.4 训练

最大熵模型的训练，就是要找到一个模型  $p^* \in \mathcal{C}$ ，并且具有最大熵  $H(p)$ 。即，

$$\begin{aligned} p^* &= \operatorname{argmax}_{p \in \mathcal{C}} H(p) \\ &= \operatorname{argmax}_{p \in \mathcal{C}} \left( - \sum_{x,y} \tilde{p}(x)p(y|x) \log p(y|x) \right) \end{aligned}$$

利用拉格朗日乘子法，我们得到：

$$\begin{aligned}\xi(p, \Lambda, \gamma) \equiv & - \sum_{x,y} \tilde{p}(x)p(y|x) \log p(y|x) \\ & + \sum_i \lambda_i \left( \sum_{x,y} \tilde{p}(x,y) f_i(x,y) - \tilde{p}(x)p(y|x) f_i(x,y) \right) \\ & + \gamma \sum_x p(y|x) - 1\end{aligned}$$

通用的训练算法有 GIS<sup>23</sup>和 IIS<sup>24</sup>算法。

## 5.2 实验结果

我们使用正负 3500 条训练评论，正负 1000 条作为测试数据。实验结果如下：

feature	pos-precision	pos-recall	pos-f1	neg-precision	neg-recall	neg-f1	total
4000	92.65	84.5	88.39	85.75	93.3	89.37	88.9

## 6 基于 SVM 的情感分析

### 6.1 支持向量机

支持向量机的基本思想是：求解能够正确划分训练数据集并且几何间隔最大的分离超平面。对于线性可分的训练数据集，线性可分离超平面有无穷多个（等价于感知机），但是几何间隔最大的分离超平面只有一个。间隔最大的直观解释是：对训练集找到几何间隔最大的超平面意味着以充分大的确信度对训练数据集进行分类。<sup>19</sup>

#### 6.1.1 划分数据集

一个线性分类器的学习目标就是要在  $n$  维的数据空间中找到一个分类超平面，其方程可以表示为：

$$w^T x + b = 0$$

于是，我们得到一个分类函数：

$$f(x) = w^T x + b$$

为了便于计算距离，我们将分类标签设为 1 和 -1。

### 6.1.2 最大化间隔

这个分类超平面要满足这样的条件：找到离分割超平面最近的点，确保它们离分割超平面的距离尽可能远。<sup>25</sup>

令  $\gamma$  为离分割超平面最近的点  $x$  到分类超平面的距离：

$$\gamma = \frac{w^T x + b}{\|w\|} = \frac{f(x)}{\|w\|}$$

不过这里的  $\gamma$  是带符号的，我们需要的只是它的绝对值，因此类似地，也乘上对应的类别  $y$  即可：

$$\tilde{\gamma} = y\gamma = \frac{\hat{\gamma}}{\|w\|}$$

其中， $\hat{\gamma} = y * (w^T x + b) = y * f(x)$ 。我们的目标便是： $\max \tilde{\gamma}$ 。方便推导和优化的目的，

我们可以令  $\hat{\gamma} = 1$ 。上述的目标函数  $\tilde{\gamma}$  转化为：

$$\max \frac{1}{\|w\|}, \quad s.t., y_i(w^T x_i + b) \geq 1, i = 1, \dots, n$$

这个问题等价于：

$$\min \frac{1}{2} \|w\|^2 \quad s.t., y_i(w^T x_i + b) \geq 1, i = 1, \dots, n$$

### 6.1.3 求解

支持向量机的求解过程比较复杂，应该说书迄今为止机器学习领域中最复杂的推导过程之一。<sup>26</sup>

我们引入拉格朗日乘子法，得到：

$$\mathcal{L}(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i (y_i(w^T x_i + b) - 1)$$

然后令

$$\theta(w) = \max_{\alpha_i \geq 0} \mathcal{L}(w, b, \alpha)$$

根据 KKT 条件，上述最优化问题必须满足：

1.  $h_j(\mathbf{x}_*) = 0, j = 1, \dots, p, g_k(\mathbf{x}_*) \leq 0, k = 1, \dots, q,$
  2.  $\nabla f(\mathbf{x}_*) + \sum_{j=1}^p \lambda_j \nabla h_j(\mathbf{x}_*) + \sum_{k=1}^q \mu_k \nabla g_k(\mathbf{x}_*) = \mathbf{0},$
- $$\lambda_j \neq 0, \mu_k \geq 0, \mu_k g_k(\mathbf{x}_*) = 0.$$

要求解这个最优化问题，首先固定  $\alpha$ ，要让  $\mathcal{L}$  关于  $w, b$  最小化，我们分别对  $w, b$  求导：

$$\frac{\partial \mathcal{L}}{\partial w} = 0 \Rightarrow w = \sum_{i=1}^n \alpha_i y_i x_i$$

$$\frac{\partial \mathcal{L}}{\partial b} = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0$$

将上述结果带回  $\mathcal{L}$ ：

$$\mathcal{L}(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i (y_i (w^T x_i + b) - 1)$$

得到：

$$\begin{aligned} \mathcal{L}(w, b, \alpha) &= \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j - \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j - b \sum_{i=1}^n \alpha_i y_i + \sum_{i=1}^n \alpha_i \\ &= \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j \end{aligned}$$

此时的  $\mathcal{L}(w, b, \alpha)$  函数只剩下一个变量  $\alpha$ 。只要求出  $\alpha$ ， $w, b$  便能求解出来。分类函数  $f(x) = w^T x + b$  也就能轻而易举求出来了。

## 6.2 实验结果

我们采用 Python 机器学习包 scikit-learn 来进行 SVM 的情感分析。使用正负 3500 条训练评论，正负 1000 条作为测试数据，特征数 4000。实验结果如下：

Feature	pos- precision	pos- recall	pos-f1	neg- precision	neg- recall	neg-f1	total
TFIDF	91.54	82.2	86.62	83.85	92.4	87.92	87.3

## 7 多分类器融合的情感分析


### 7.1 多分类器融合

#### 7.1.1 Bayes + MaxEnt + SVM

K-NN 的分类精度不是很高，训练效率也不是很好，所以，我们准备采用贝叶斯 + 最大熵 + 支持向量机进行融合。从上述分析中，本文汇总出各分类器的分类准确率，如下：

classifier	pos-precision	neg-precision	Pos-recall	Neg-recall	total
Bayes	91.10	75.4	69.6	93.2	81.4
MaxEnt	92.65	85.76	84.5	93.3	88.9
SVM	91.54	83.85	82.2	92.4	87.3

在多分类器融合中，本文首先测试将贝叶斯、最大熵、支持向量机进行并联融合，其并联融合流程为：



本文首先测试简单的加权平均策略。若  $C_i$  为分类为  $i$  的分类器个数，则多分类器融合下的情感分类为：

$$i = \operatorname{argmax}(C_i).$$

使用正负各 3500 条训练评论，正负各 1000 条作为测试数据，特征数为 4000。测试结果如下：

feature	pos-precision	pos-recall	pos-f1	neg-precision	neg-recall	neg-f1	total
4000	93.2948	80.7	86.54155	82.99559	94.2	88.24356	87.45

分类精度低于最大熵，但高于 SVM 和贝叶斯。说明此种策略无效。

于是，本文尝试用引入置信度  $C$  的概念。置信度  $C_{i-j}$  表示分类器  $j$  对于输入数据分类为  $i$  的置信度。三种分类器中，最大熵判断一条语句为正向时，其正确的可能性为 92.65%，所以其正向置信度  $C$  为 92.65%。贝叶斯判断一条语句为正向时，其正确的可能性为 91.1%，所以其

正向置信度 C 为 91.1%。SVM 判断一条语句为正向时，其正确的可能性为 91.54%，所以其正向置信度 C 为 91.54%。各分类器负向置信度如是。另外， $N_i$  表示分类为 i 的分类器数目，其中 i 取 0 和 1。则，多分类器并联融合下的情感分类为：

$$i = \begin{cases} \operatorname{argmax} \left( \frac{\sum_j C_{i-j}}{N_i} \right) & \text{若 } N_i \neq 0 \\ 0 & \text{若 } N_1 = 0 \\ 1 & \text{若 } N_0 = 0 \end{cases}$$

使用正负各 3500 条训练评论，正负各 1000 条作为测试数据，特征数为 4000。测试结果与单个分类器比较如下：

Classifier	pos-precision	pos-recall	pos-f1	neg-precision	neg-recall	neg-f1	total-recall
Fusion	88.74879	91.5	90.1034	91.22807	88.4	89.79177	89.95
Bayes	91.10	69.6	75.4	75.4	93.2	83.36	81.4
MaxEnt	92.65	84.5	88.39	85.75	93.3	89.37	88.9
SVM	91.54	82.2	86.62	83.85	92.4	87.92	87.3

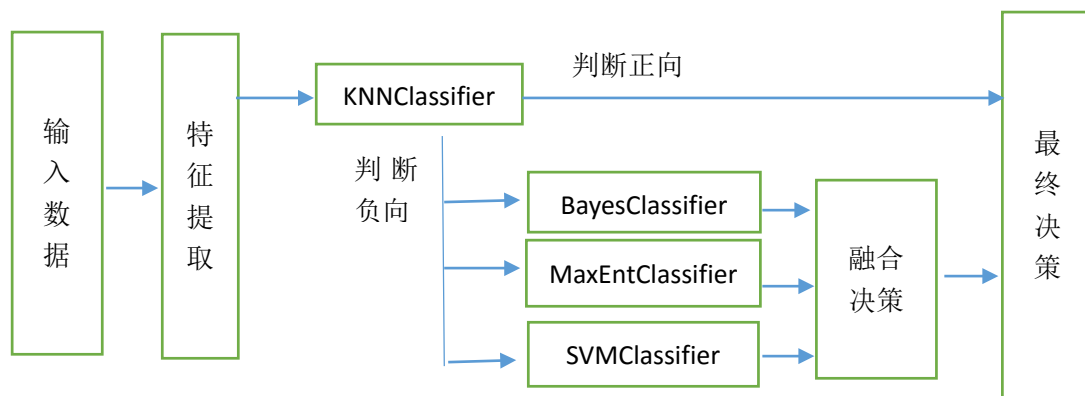
正向分类精度小于单个分类器，正向召回率高于单个分类器，负向分类精度高于单个分类器，负向召回率又小于单个分类器，整体看分类精度明显高于单个分类器。说明这种多分类器融合的置信平均策略是有效的。

### 7.1.2 K-NN + Bayes + MaxEnt + SVM

另外，虽然 k-NN 测效率不高，正确率不好，但是，本文从测试数据中发现，当 k=1 时，K-NN 的正向分类精度几乎达到 100%。

Neg-right	neg-false	pos-right	pos-false	pos-precision	pos-recall
999	392	608	1	99.8358	60.8
pos-f1	neg-precision	neg-recall	neg-f1	total	
75.57489	71.81884	99.9	83.56336	80.35	

K-NN 在判断为 609 个正向情感中，只有 1 个分类错误。于是，本文尝试对单个语句，先用 K-NN 进行极性判断，如果为正向，则直接判断该句为正向，若不为正向，使用多分类融合的置信平均策略进行极性分析，即多分类器的串联+并联融合。此种多分类器混合融合策略流程如下：



本文使用正负各 3500 条训练评论，正负各 1000 条作为测试数据，特征数为 4000。测试结果与多分类器并联融合的置信平均策略比较如下：

	pos-precision	pos-recall	pos-f1	neg-precision	neg-recall	neg-f1	total-recall
混合	88.40304	93	90.64327	92.61603	87.8	90.14374	90.4
并联	88.74879	91.5	90.1034	91.22807	88.4	89.79177	89.95

## 7.2 结论

实验结果证明，多分类器并联融合的加权平均策略，是无效的，应该采用置信平均策略，这种置信平均策略，能将情感极性分析准确率提升 1 个百分点。而多分类器混合融合（并联+串联）的置信平均策略，能进一步将情感极性分析准确率提升。另外，本文认为，这种多分类器混合融合策略，需要根据具体情况而定，谁与谁并联，谁与谁串联。

## 参考文献：

- <sup>1</sup> 赵妍妍，秦兵，刘挺. 文本情感分析 [J]. 软件学报，2010，21( 8) : 1834-1848.
- <sup>2</sup> Pang, Bo, and Lillian Lee. 2008. "Opinion Mining and Sentiment Analysis." Foundations and Trends® in Information Retrieval 2: 1-135.
- <sup>3</sup> K. Vivekanandan, J. Soonu Aravindan. 2014. Aspect-based Opinion Mining: A Survey. International Journal of Computer Applications (0975 – 8887) Volume 106 – No.3, November 2014
- <sup>4</sup> Pang, Bo, Lillian Lee, and Shivakumar Vaithyanathan. 2002. "Thumbs up? Sentiment Classification Using Machine Learning Techniques." In Conference on Empirical Methods in Natural Language Processing (EMNLP 2002), 79-86.
- <sup>5</sup> Turney, Peter D. 2001. "Thumbs up or thumbs down?: semantic orientation applied to unsupervised classification of reviews." In Proceedings of the 40th Annual Meeting on Association for Computational Linguistics, ACL '02 417- 424.
- <sup>6</sup> Yu, Lei, Jia Ma, Seiji Tsuchiya, and Fuji Ren. 2008. "Opinion Mining: A Study on Semantic Orientation Analysis for Online Document." In Proceedings of the World Congress on Intelligent Control and Automation (WCICA), 4548-52.
- <sup>7</sup> Liu, Jingjing et al. 2007. "Low-Quality Product Review Detection in Opinion Summarization." In Computational Linguistics, 334-42.

- 
- <sup>8</sup> Lim, Ee-Peng et al. 2010. "Detecting Product Review Spammers Using Rating Behaviors." Proceedings of the 19th ACM International Conference on Information and Knowledge Management: 939–48.
- <sup>9</sup> Wiebe, Janyce et al. 2004. "Learning Subjective Language." Computational Linguistics 30: 277–308.
- <sup>10</sup> 熊德兰, 程菊明, 田胜利. 基于 HowNet 的句子褒贬倾向性研究. 计算机工程与应用, 2008, 44(22): 143—144.
- <sup>11</sup> Huang, Shen et al. 2009. "Improving Product Review Search Experiences on General Search Engines." In Proceedings of the 11th International Conference on Electronic Commerce - ICEC '09, 107.
- <sup>12</sup> Moghaddam, Samaneh, and Martin Ester. 2011. "AQA: Aspect-Based Opinion Question Answering." In Proceedings - IEEE International Conference on Data Mining, ICDM, 89–96.
- <sup>13</sup> Hu, Mingqing, and Bing Liu. 2004. "Mining and Summarizing Customer Reviews." Proceedings of the 2004 ACM SIGKDD international conference on Knowledge discovery and data mining KDD 04 04: 168.
- <sup>14</sup> Lu, Yue, ChengXiang Zhai, and Neel Sundaresan. 2009. "Rated Aspect Summarization of Short Comments." Proceedings of the 18th international conference on World wide web - WWW '09: 131.
- <sup>15</sup> Wong, Tak-Lam, Wai Lam, and Tik-Shun Wong. 2008. "An Unsupervised Framework for Extracting and Normalizing Product Attributes from Multiple Web Sites." Proceedings of the 31st annual international ACM SIGIR conference on Research and development in information retrieval SIGIR 08: 35.
- <sup>16</sup> Liu, Bing, and South Morgan Street. 2005. "Opinion Observer : Analyzing and Comparing Opinions on the Web." In Proceedings of the 14th International Conference on World Wide Web, 342–51.
- <sup>17</sup> 硕士论文.基于情感词典的中文微博情感倾向分析研究.陈晓东. 2012 年 1 月 12 日
- <sup>18</sup> MADEIRA H. COSTA J, VIEIRA M. The OLAP and data warehousing approaches for analysis and sharing of results from dependability evaluation experiments[C] / / International Conference on Dependable Systems and Networks. [S. 1. ]: IEEE Press, 2003: 86—91.
- <sup>19</sup> 《统计学习方法》,李航, 清华大学出版社,2012.3
- <sup>20</sup> Harry Zhang. The Optimality of Naive Bayes. 2004, American Association for Artificial Intelligence
- <sup>21</sup> T. Jaynes. Information Theory and Statistical Mechanics. Physics Reviews. 1 957(1 06): 620. 630
- <sup>22</sup> Adwait Ratnaparkhi, A Simple Introduction to Maximum Entropy Models for Natural Language Processing. IRCS Report 97—08
- <sup>23</sup> Darroch, J. N. and Ratcliff, D. (1972).Generalized Iterative Scaling for Log-linear Models. Annals of Mathematical Statistics, no. 43, 1470-1480
- <sup>24</sup> A Berger. The improved iterative scaling algorithm: A gentle introduction. 《Unpublished Manuscript》, 1998
- <sup>25</sup> Peter Harrington. Machine Learning In Action.2013. Manning Publications
- <sup>26</sup> 机器学习——算法原理与编程实践, 郑捷, 中国工信出版社, 电子工业出版社, 2015.11